HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1

PTIT

CHƯƠNG 04

KNOWLEDGE GRAPH VÀ RAG

Học phần: Phát triển các hệ thống thông minh

Giảng viên hướng dẫn: Thầy Trần Đình Quế

Sinh viên thực hiện: Kiều Trường Giang

Mã sinh viên: B23DCCN254

GitHub: https://github.com/jellalaz/RAG_HTTM

Web demo: https://rag-httm-ai.vercel.app

Hà Nội - 2026

MỤC LỤC

4.1. MỞ ĐẦU . . . 3
4.1.1. LỊCH SỬ PHÁT TRIỂN CỦA KNOWLEDGE GRAPH . . . 4
4.1.1. LỊCH SỬ PHÁT TRIỂN CỦA RAG . . . 5
4.1.2. VAI TRÒ VÀ Ý NGHĨA TRONG AI . . . 6
4.1.3. PHẠM VI, CÂU HỎI VÀ ĐÓNG GÓP . . . 7
4.2. KNOWLEDGE GRAPH - KNOWLEDGE BASE . . . 8
4.2.1. BỘ BA, THỰC THỂ VÀ QUAN HỆ . . . 9
4.2.2. KNOWLEDGE GRAPH CORE ENGINE . . . 10
4.2.3. RDF VÀ LABELED PROPERTY GRAPH . . . 11
4.2.4. CHẤT LƯỢNG VÀ QUẢN TRỊ TRI THỨC . . . 12
4.3. RAG - RETRIEVAL-AUGMENTED GENERATION . . . 13
4.3.1. NẠP, LẬP CHỈ MỤC VÀ TRUY XUẤT . . . 14
4.3.2. TRUY XUẤT ĐỒ THỊ VÀ SUY LUẬN NHIỀU BƯỚC . . . 15
4.3.3. TỔNG HỢP CÂU TRẢ LỜI CÓ CĂN CỨ . . . 16
4.3.4. ĐÁNH GIÁ RAG VÀ GRAPHRAG . . . 17
4.4. KB VÀ RAG CHO BỆNH TIỂU ĐƯỜNG . . . 18
4.4.1. ONTOLOGY VÀ XỬ LÝ DỮ LIỆU Y TẾ . . . 19
4.4.2. THỰC NGHIỆM HỎI ĐÁP Y TẾ . . . 20
4.4.3. GIỚI HẠN VÀ HƯỚNG MỞ RỘNG Y TẾ . . . 21
4.5. KB VÀ RAG CHO CHỨNG KHOÁN . . . 22
4.5.1. DỮ LIỆU VÀ TIỀN XỬ LÝ FPT . . . 23
4.5.2. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH FPT . . . 24
4.5.3. HỎI ĐÁP CHỨNG KHOÁN VỚI GRAPHRAG . . . 25
4.5.4. RỦI RO VÀ HƯỚNG MỞ RỘNG . . . 26
4.6. KB VÀ RAG CHO GIÁ VÀNG . . . 27
4.6.1. DỮ LIỆU, CHỈ BÁO VÀ KNOWLEDGE GRAPH VÀNG . . . 28
4.6.2. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH VÀNG . . . 29
4.6.3. HỎI ĐÁP VĨ MÔ VỚI GRAPHRAG . . . 30
4.6.4. GIỚI HẠN VÀ HƯỚNG MỞ RỘNG . . . 31
4.7. DEPLOYMENT . . . 32
4.7.1. SUY LUẬN MÔ HÌNH TRÊN TRÌNH DUYỆT . . . 33
4.7.2. CHATBOT RAG SỨC KHỎE VÀ DINH DƯỠNG . . . 34
4.7.3. KIỂM THỬ TRIỂN KHAI . . . 35

PHỤ LỤC A - TỔNG HỢP HUẤN LUYỆN BA MIỀN **38**

PHỤ LỤC B - KẾT QUẢ TRUY XUẤT **39**

PHỤ LỤC C - MẪU BỘ BA TRI THỨC **40**

TÀI LIỆU THAM KHẢO **41**

Repository: https://github.com/jellalaz/RAG_HTTM

Web demo: https://rag-httm-ai.vercel.app

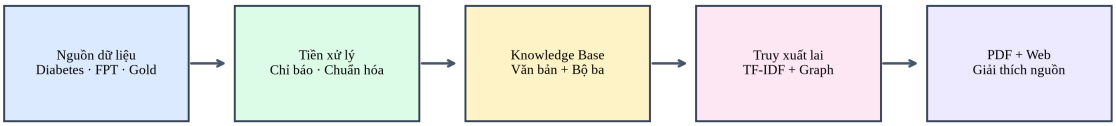
4.1. MỞ ĐẦU

Knowledge Graph (KG) và Retrieval-Augmented Generation (RAG) xuất phát từ hai truyền thống khác nhau. KG nhấn mạnh biểu diễn tường minh: thực thể nào tồn tại, chúng liên hệ ra sao và ràng buộc nào phải được giữ. RAG xuất phát từ nhu cầu cho mô hình sinh tiếp cận một kho tri thức ngoài tại thời điểm trả lời. Khi ghép hai hướng này, hệ thống vừa có khả năng tìm kiếm mềm theo ngôn ngữ, vừa có cấu trúc để kiểm tra đường suy luận.

Bài làm lựa chọn kiến trúc có thể chạy trọn trong một notebook. TF-IDF đảm nhiệm truy xuất văn bản, NetworkX lưu đồ thị, còn bộ tổng hợp ghép bằng chứng tìm được thành câu trả lời. Dữ liệu FPT.VN và GC=F được tải trực tiếp khi chạy; dữ liệu tiểu đường lấy từ scikit-learn.

Ba miền được chọn tạo ra phép thử đủ khác biệt. Y tế yêu cầu diễn đạt thận trọng; chứng khoán là chuỗi thời gian nội địa; vàng chịu tác động của yếu tố vĩ mô và được niêm yết quốc tế. Một pipeline dùng chung phải giữ được ngữ cảnh riêng của từng miền mà không trộn lẫn bằng chứng.

Kiến trúc thực nghiệm Knowledge Graph và RAG



Hình: 4.1. MỞ ĐẦU

4.1.1. LỊCH SỬ PHÁT TRIỂN CỦA KNOWLEDGE GRAPH

Ý tưởng nối các khái niệm thành mạng ngữ nghĩa đã xuất hiện từ những nghiên cứu ban đầu về trí nhớ và biểu diễn tri thức. Sau đó, hệ chuyên gia đưa luật IF-THEN vào các miền hẹp. Bước ngoặt của Web ngữ nghĩa là việc chuẩn hóa RDF, RDFS, OWL và SPARQL, khiến bộ ba chủ thể-vị từ-đối tượng trở thành một ngôn ngữ trao đổi máy đọc được [1], [2].

Năm 2012, cách gọi Knowledge Graph được phổ biến rộng rãi qua công cụ tìm kiếm của Google. Trong doanh nghiệp, KG tiếp tục được dùng cho danh mục sản phẩm, phát hiện gian lận, quản trị dữ liệu chủ và gợi ý nội dung. Điểm chung không phải một loại cơ sở dữ liệu cụ thể, mà là cách coi quan hệ giữa các thực thể là công dân hạng nhất.

Ở bài này, đồ thị được cài bằng Labeled Property Graph đơn giản. Mỗi nút có type và domain; mỗi cạnh có nhãn quan hệ. Lựa chọn này gần với cách Neo4j tổ chức dữ liệu và thuận tiện cho trực quan hóa, dù chưa khai thác đầy đủ suy luận ontology như OWL.

4.1.1. LỊCH SỬ PHÁT TRIỂN CỦA RAG

Trước RAG, các hệ hỏi đáp mở thường tách bộ tìm kiếm tài liệu và bộ đọc hiểu. REALM đưa cơ chế truy xuất vào quá trình tiền huấn luyện [3]. Lewis và cộng sự sau đó định danh kiến trúc Retrieval-Augmented Generation, kết hợp bộ truy xuất dense với mô hình sinh seq2seq cho nhiệm vụ giàu tri thức [4].

Sự phổ biến của mô hình ngôn ngữ lớn khiến RAG trở thành một mẫu triển khai thực dụng: tài liệu có thể cập nhật mà không cần huấn luyện lại toàn bộ mô hình, đồng thời câu trả lời giữ được liên kết về nguồn. Tuy nhiên, vector search thường ưu tiên đoạn giống câu hỏi và có thể bỏ qua quan hệ gián tiếp. GraphRAG giải quyết phần thiếu này bằng việc xây thực thể, quan hệ, cụm và tóm tắt theo cấu trúc [5].

Nguyên mẫu trong notebook không cố tái tạo toàn bộ Microsoft GraphRAG. Nó giữ hai ý cốt lõi: truy xuất đồng thời từ văn bản và đồ thị, sau đó đưa cả hai nhóm bằng chứng vào bước tổng hợp.

4.1.2. VAI TRÒ VÀ Ý NGHĨA TRONG AI

KG giúp mô hình có từ điển thực thể thống nhất, quan hệ có tên và đường đi có thể kiểm tra. RAG giúp tri thức ngoài đi vào ngữ cảnh trả lời đúng thời điểm. Kết hợp hai thành phần làm giảm nguy cơ câu trả lời chỉ dựa trên tương đồng bề mặt, nhưng không đồng nghĩa loại bỏ hoàn toàn sai sót.

Trong y tế, giá trị quan trọng nhất là provenance: người đọc phải biết nhận xét dựa trên biến nào và nguồn nào. Trong tài chính, dữ liệu có tính thời điểm nên ngày quan sát phải đi cùng con số. Trong cả hai trường hợp, câu trả lời nên phân biệt sự kiện đo được, quan hệ thường gặp và kết luận mang tính dự báo.

Ý nghĩa học thuật của bài nằm ở khả năng chạy lại. Người chấm có thể Run All, xem dữ liệu thô đã lưu, đối chiếu bộ ba, kiểm tra tài liệu được truy xuất và mở PDF được sinh từ cùng một trạng thái chạy.

4.1.3. PHẠM VI, CÂU HỎI VÀ ĐÓNG GÓP

Bài đặt ba câu hỏi: (1) một cấu trúc KG thống nhất có mô tả được ba miền khác nhau không; (2) truy xuất lai có cung cấp nhiều bằng chứng hơn vector search đơn lẻ không; và (3) có thể đóng gói toàn bộ quy trình trong một notebook duy nhất không.

Đóng góp thực hành gồm lớp KnowledgeGraphCore, bộ tải Yahoo Finance không cần API key, các bước tạo chỉ báo, VectorRetriever, truy xuất đồ thị theo miền, đánh giá precision@3, ứng dụng dự đoán, chatbot sức khỏe có nguồn và bộ sinh PDF. Mọi tệp phụ đều được tạo lại từ notebook.

Ba nguồn dữ liệu được mô tả bằng số dòng, số cột, khoảng thời gian, đơn vị và biến đích. Bảng được sinh trực tiếp từ DataFrame sau xử lý nên khớp với lần chạy hiện tại.

Mô tả ba nguồn dữ liệu tại thời điểm chạy

Miền	Nguồn	Số dòng	Số cột	Phạm vi	Biến đích/đơn vị
Tiểu đường	scikit-learn load_diabetes	442	11	442 mẫu nghiên cứu	mức tiến triển sau 1 năm
Chứng khoán	Yahoo Finance chart API — FPT.VN	523	10	15/10/2024 - 15/10/2026	Close phiên kế tiếp (VND)
Giá vàng	Yahoo Finance chart API — GC=F	504	10	15/10/2024 - 15/10/2026	Close phiên kế tiếp (USD/oz)

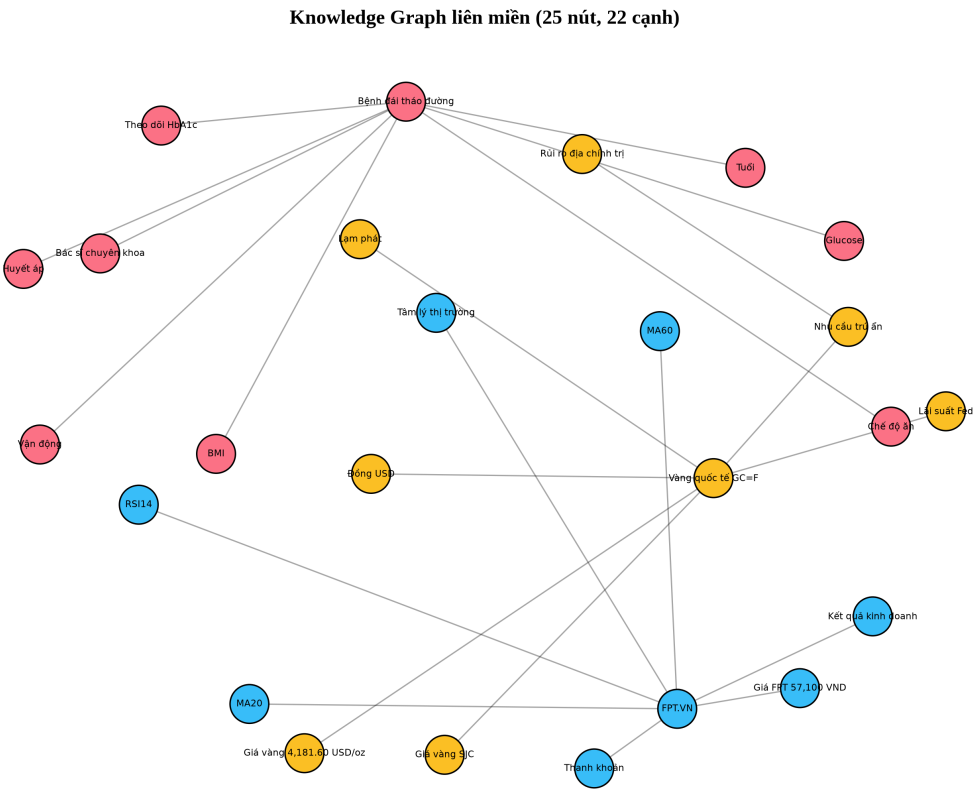
Hình: 4.1.3. PHẠM VI, CÂU HỎI VÀ ĐÓNG GÓP

4.2. KNOWLEDGE GRAPH - KNOWLEDGE BASE

Knowledge Base trong bài gồm hai lớp. Lớp văn bản giữ các đoạn mô tả dữ liệu, phương pháp và kết quả theo từng miền. Lớp đồ thị giữ thực thể cùng các quan hệ có hướng. Hai lớp dùng chung nhãn domain để ngăn truy xuất nhầm giữa tiểu đường, cổ phiếu và vàng.

Đồ thị tại lần chạy này có 25 nút và 22 cạnh. Kích thước nhỏ giúp người đọc kiểm tra thủ công. Khi mở rộng, cùng schema có thể chuyển sang Neo4j hoặc một triple store mà không thay đổi ý nghĩa bộ ba.

Knowledge Base không chỉ chứa kiến thức tĩnh. Các nút quan sát như giá FPT hoặc giá vàng gần nhất được tạo từ dữ liệu tải về. Cách làm này nối câu trả lời với đúng trạng thái thị trường tại thời điểm chạy.



Hình: 4.2. KNOWLEDGE GRAPH - KNOWLEDGE BASE

4.2.1. BỘ BA, THỰC THỂ VÀ QUAN HỆ

Một bộ ba có dạng (s, p, o), trong đó s là thực thể nguồn, p là quan hệ có tên và o là thực thể hoặc giá trị đích. Ví dụ: (MA20, MÔ_TẢ_XU_HƯỚNG_NGẮN_HẠN_CỦA, FPT.VN). Bộ ba này không khẳng định xu hướng sẽ tiếp diễn; nó chỉ diễn tả vai trò của chỉ báo.

Thực thể được gắn type như Condition, Biomarker, Stock, TechnicalIndicator, Commodity hoặc MacroFactor. Thuộc tính domain tách ba không gian nghiệp vụ. Tên quan hệ dùng động từ viết hoa để người đọc có thể đọc thành câu.

Việc chọn quan hệ là công đoạn có tính chủ quan. Báo cáo ưu tiên từ CÓ_THỂ_TÁC_ĐỘNG hoặc CÓ_QUAN_HỆ... thay vì GÂY_RA khi dữ liệu không đủ để chứng minh nhân quả.

4.2.2. KNOWLEDGE GRAPH CORE ENGINE

Lớp KnowledgeGraphCore bọc MultiDiGraph của NetworkX. add_entity quản lý nút và thuộc tính; add_relation thêm cạnh có hướng; neighbors trả về bằng chứng một bước; multi_hop tìm các đường đơn trong giới hạn số hop. Cấu trúc MultiDiGraph cho phép hai thực thể có nhiều loại quan hệ.

Độ phức tạp của truy vấn lân cận tỷ lệ với bậc của nút. Truy vấn mọi đường đơn có thể tăng nhanh theo kích thước đồ thị, vì vậy max_hops phải được giới hạn. Với đồ thị sản xuất, cần chỉ mục, phân quyền và chiến lược truy vấn cụ thể thay vì duyệt toàn bộ.

Toàn bộ cạnh được xuất thành knowledge_graph_triples.csv. Đây là điểm kiểm tra thuận tiện: mỗi dòng trong tệp phải đọc được như một phát biểu, không có nút mồ côi vô nghĩa và không chứa con số không rõ ngày.

KnowledgeGraphCore: thực thể, quan hệ và multi-hop Tieuluan02_06_Nhom2_Giangkt.ipynb

```
class KnowledgeGraphCore:
    def __init__(self):
        self.graph = nx.MultiDiGraph()

    def add_entity(self, entity_id, entity_type="Entity", **properties):
        self.graph.add_node(entity_id, type=entity_type, **properties)

    def add_relation(self, subject, predicate, obj, weight=1.0, **properties):
        if subject not in self.graph: self.add_entity(subject)
        if obj not in self.graph: self.add_entity(obj)
        self.graph.add_edge(subject, obj, key=predicate,
                            relation=predicate, weight=float(weight), **properties)

    def multi_hop(self, start, max_hops=2):
        paths = []
        for target in self.graph.nodes:
            if target != start:
                paths.extend(nx.all_simple_paths(self.graph, start, target, cutoff=max_hops))
        return paths
```

Hình: 4.2.2. KNOWLEDGE GRAPH CORE ENGINE

4.2.3. RDF VÀ LABELED PROPERTY GRAPH

RDF phù hợp khi cần URI toàn cục, liên kết dữ liệu và suy luận theo chuẩn W3C. Labeled Property Graph thuận tiện khi cạnh cần thuộc tính và truy vấn đường đi là trọng tâm. Bài chọn mô hình thứ hai vì mục tiêu là nguyên mẫu phân tích và trực quan hóa bằng Python.

Nếu chuyển sang RDF, các entity_id cần ánh xạ thành IRI; relation thành predicate; giá trị số thành literal có datatype. Nếu chuyển sang Neo4j, type có thể thành node label, relation thành relationship type và các trường domain/source thành property.

Không có mô hình nào tốt tuyệt đối. Tiêu chí chọn là khả năng tích hợp với hệ thống, yêu cầu suy luận, quy mô và kỹ năng vận hành của nhóm.

4.2.4. CHẤT LƯỢNG VÀ QUẢN TRỊ TRI THỨC

Một KG hữu ích cần hơn số lượng cạnh. Bốn kiểm tra tối thiểu gồm: tính duy nhất của định danh, tính hợp lệ của miền-phạm vi, nguồn gốc quan hệ và thời hạn của dữ liệu động. Các quan hệ y tế và tài chính phải có mức tin cậy hoặc câu chữ thể hiện độ bất định.

Bài hiện lưu source ở lớp tài liệu và domain ở lớp đồ thị. Bản sản xuất nên bổ sung created_at, valid_from, valid_to, confidence và evidence_id cho từng cạnh. Khi đó, một quan hệ đã cũ có thể bị loại trước khi đưa vào prompt.

Kiểm soát chất lượng cần vòng phản hồi của chuyên gia. Bác sĩ xác nhận ontology y tế; chuyên viên tài chính rà soát khái niệm và đơn vị; kỹ sư dữ liệu kiểm tra schema cùng pipeline cập nhật.

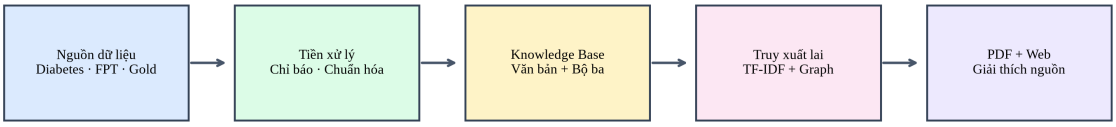
4.3. RAG - RETRIEVAL-AUGMENTED GENERATION

Pipeline RAG gồm ingestion, indexing, retrieval và generation. Văn bản được chia thành các đơn vị có nguồn; TF-IDF biến chúng thành vector; cosine similarity xếp hạng theo câu hỏi. Bước sinh ghép hai đoạn phù hợp nhất với các bộ ba liên quan.

TF-IDF được chọn vì minh bạch, nhẹ và tái lập. Hạn chế là không hiểu đồng nghĩa sâu như embedding. Để giảm nhược điểm, câu hỏi được nhận diện miền bằng một từ điển alias và GraphRAG bổ sung các quan hệ từ đồ thị.

Mỗi câu trả lời trả về cả documents, score, triples và domain. Cấu trúc này quan trọng hơn phần câu chữ: giao diện hoặc báo cáo có thể trình bày bằng chứng mà không phải phân tích ngược chuỗi văn bản.

Kiến trúc thực nghiệm Knowledge Graph và RAG



Hình: 4.3. RAG - RETRIEVAL-AUGMENTED GENERATION

4.3.1. NẠP, LẬP CHỈ MỤC VÀ TRUY XUẤT

Các tài liệu ngắn được xây từ mô tả bộ dữ liệu và kết quả thực nghiệm. Trong hệ thống lớn, ingestion cần đọc PDF, HTML hoặc cơ sở dữ liệu; chuẩn hóa Unicode; bỏ trùng; chia đoạn theo ngữ nghĩa; và gắn metadata trước khi embedding.

TfidfVectorizer dùng unigram và bigram. Bigram giúp phân biệt các cụm như giá vàng, tiểu đường, lãi suất Fed. top_k=3 giữ ngữ cảnh ngắn và dễ kiểm tra. Precision@3 theo domain được dùng như phép đo đơn giản cho độ đúng của truy xuất.

Điểm cosine chỉ phản ánh độ gần từ vựng, không phải độ đúng. Vì vậy báo cáo không diễn giải score như xác suất và không tự động loại bỏ nguồn chuyên môn chỉ vì score thấp.

VectorRetriever dùng TF-IDF và cosine similarity Tieuluan02_06_Nhom2_Giangkt.ipynb

```
class VectorRetriever:
    def __init__(self, docs):
        self.docs = docs
        self.vectorizer = TfidfVectorizer(
            lowercase=True, ngram_range=(1, 2), min_df=1,
            token_pattern=r"(?u)\b\w+\b"
        )
        self.matrix = self.vectorizer.fit_transform([d["text"] for d in docs])

    def search(self, query, top_k=3):
        query_vector = self.vectorizer.transform([query])
        scores = cosine_similarity(query_vector, self.matrix).ravel()
        order = np.argsort(scores)[::-1][:top_k]
        return [{**self.docs[i], "score": float(scores[i])} for i in order]
```

Hình: 4.3.1. NẠP, LẬP CHỈ MỤC VÀ TRUY XUẤT

4.3.2. TRUY XUẤT ĐỒ THỊ VÀ SUY LUẬN NHIỀU BƯỚC

graph_evidence nhận diện miền, chọn các nút cùng domain hoặc trùng từ khóa, rồi lấy quan hệ vào và ra. Phương án này đủ cho đồ thị nhỏ. Khi đồ thị lớn, cần entity linking, tìm kiếm theo embedding của nhãn và truy vấn Cypher có giới hạn.

Suy luận nhiều bước được minh họa bởi chuỗi Rủi ro địa chính trị → Nhu cầu trú ẩn → Vàng quốc tế. Vector search có thể tìm một đoạn nói về địa chính trị nhưng không mặc nhiên biểu diễn hai quan hệ riêng. Đồ thị giúp giữ cấu trúc của lời giải thích.

Đường đi chỉ là bằng chứng cấu trúc, không tự chứng minh nhân quả. Mọi kết luận vẫn phụ thuộc chất lượng cạnh và nguồn đã dùng để tạo cạnh.

GraphRAG: ghép bằng chứng văn bản và bộ ba Tieuluan02_06_Nhom2_Giangkt.ipynb

```
def graphrag_answer(query, top_k=3):
    docs = retriever.search(query, top_k=top_k)
    triples = graph_evidence(query)
    domain = detect_domain(query)
    domain_docs = [d for d in docs if d["domain"] in (domain, "method")]
    statements = [d["text"] for d in domain_docs[:2]]
    graph_text = [f"{s} -[{p}]-> {o}" for s, p, o in triples[:3]]
    answer = " ".join(statements)
    if graph_text:
        answer += " Quan hệ đồ thị: " + "; ".join(graph_text)
    return {"answer": answer, "documents": domain_docs, "triples": triples}
```

Hình: 4.3.2. TRUY XUẤT ĐỒ THỊ VÀ SUY LUẬN NHIỀU BƯỚC

4.3.3. TỔNG HỢP CÂU TRẢ LỜI CÓ CĂN CỨ

Bộ sinh trong bài là deterministic synthesizer. Nó chọn hai tài liệu phù hợp, nối tối đa ba quan hệ đồ thị và thêm cảnh báo theo miền. Kết quả ít tự nhiên hơn LLM nhưng có lợi thế là chạy offline và không tự thêm sự kiện ngoài bằng chứng.

Có thể thay bộ sinh bằng một LLM cục bộ hoặc dịch vụ API. Khi đó prompt phải tách rõ QUESTION, TEXT EVIDENCE, GRAPH EVIDENCE và yêu cầu từ chối nếu bằng chứng thiếu. Đầu ra nên ở dạng JSON để kiểm tra citation_id.

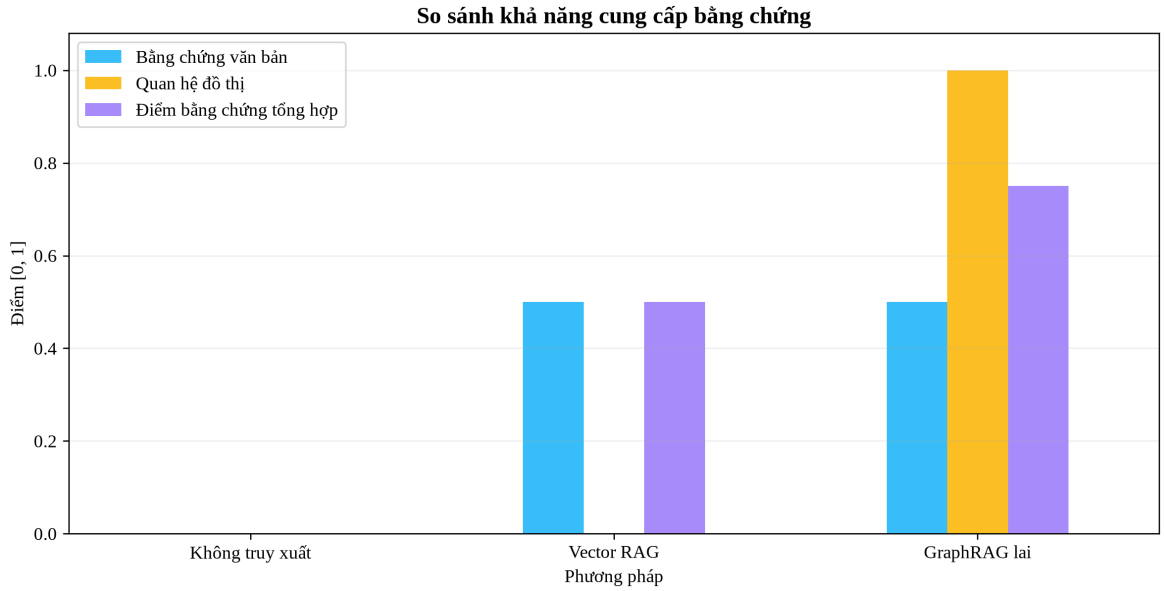
Thiết kế production cần chống prompt injection từ tài liệu, lọc dữ liệu nhạy cảm, theo dõi phiên bản chỉ mục và ghi log các nguồn đã đưa cho mô hình.

4.3.4. ĐÁNH GIÁ RAG VÀ GRAPHRAG

Bộ kiểm thử gồm sáu câu hỏi, hai câu cho mỗi miền. vector_precision@3 đo tỷ lệ tài liệu thuộc đúng miền trong ba kết quả đầu. graph_evidence ghi nhận hệ thống có tìm được cạnh liên quan hay không. Điểm tổng hợp cộng một phần thưởng nhỏ khi cả hai kênh đều có bằng chứng.

Ở lần chạy này, precision@3 trung bình là 0.500; tỷ lệ câu hỏi có bằng chứng đồ thị là 1.000; điểm bằng chứng lai là 0.750.

Đây là smoke test, chưa phải benchmark khoa học. Một đánh giá đầy đủ cần nhiều câu hỏi do người độc lập soạn, đáp án chuẩn, chấm faithfulness, answer relevance, citation correctness, độ trễ và chi phí.



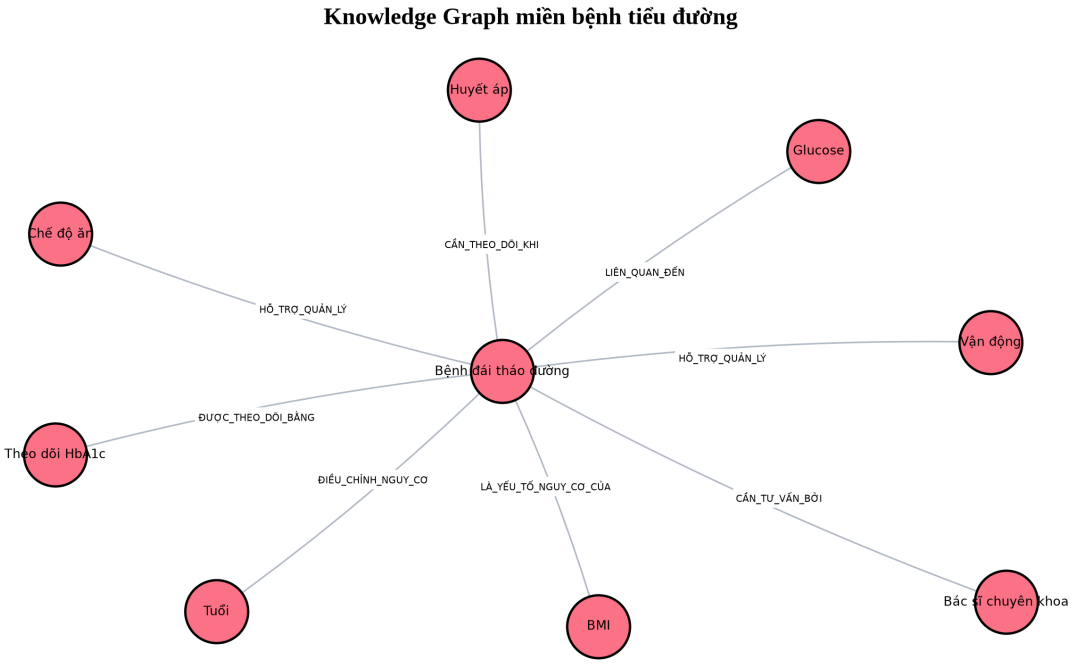
Hình: 4.3.4. ĐÁNH GIÁ RAG VÀ GRAPHRAG

4.4. KB VÀ RAG CHO BỆNH TIỂU ĐƯỜNG

Bộ dữ liệu diabetes của scikit-learn có 442 quan sát và 10 biến đầu vào đã chuẩn hóa. Biến đích là chỉ số định lượng mức tiến triển bệnh sau một năm. Dữ liệu không chứa tên, mã hồ sơ hay thông tin nhận dạng cá nhân.

Bốn cấu hình được so sánh bằng K-fold 5 phần trên tập train: Linear Regression, Ridge, Random Forest và Gradient Boosting. Tập test 20% được giữ riêng cho đến khi đã chọn mô hình theo CV MAE.

Mô hình được chọn là Ridge; CV MAE = 45.00, test MAE = 42.81, RMSE = 53.78, R^2 = 0.454. Tham số: {'model__alpha': 1.0}.



Hình: 4.4. KB VÀ RAG CHO BỆNH TIỂU ĐƯỜNG

4.4.1. ONTOLOGY VÀ XỬ LÝ DỮ LIỆU Y TẾ

Ontology tối giản gồm Condition, Biomarker, RiskFactor, Lifestyle, Monitoring và Professional. Các quan hệ như LIÊN_QUAN_ĐẾN hoặc HỖ_TRỢ_QUẢN_LÝ được chọn để tránh biến một tương quan thành chỉ định điều trị.

Dữ liệu không có tên bệnh nhân hay định danh cá nhân. Trong tình huống thực, hồ sơ y tế cần mã hóa, phân quyền theo vai trò, nhật ký truy cập và quy trình chấp thuận. Không nên đưa thông tin nhận dạng vào dịch vụ embedding công cộng khi chưa có cơ sở pháp lý.

Mô hình Ridge được chọn theo MAE trung bình của 5 fold. Permutation importance được tính trên tập test để cùng một cách giải thích áp dụng được cho cả mô hình tuyến tính và mô hình cây.

Tuning Random Forest bằng 5-fold CV Tieuluan02_06_Nhom2_Giangkt.ipynb

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
cv = KFold(n_splits=5, shuffle=True, random_state=42)
rf_grid = {
    "n_estimators": [250, 400],
    "max_depth": [None, 8, 14],
    "min_samples_leaf": [2, 4, 6],
    "max_features": [0.7, 1.0],
}
search = GridSearchCV(
    RandomForestRegressor(random_state=42, n_jobs=1),
    param_grid=rf_grid, scoring="neg_mean_absolute_error",
    cv=cv, n_jobs=1, refit=True,
)
search.fit(X_train, y_train)
diabetes_model = search.best_estimator_
diabetes_pred = diabetes_model.predict(X_test)
```

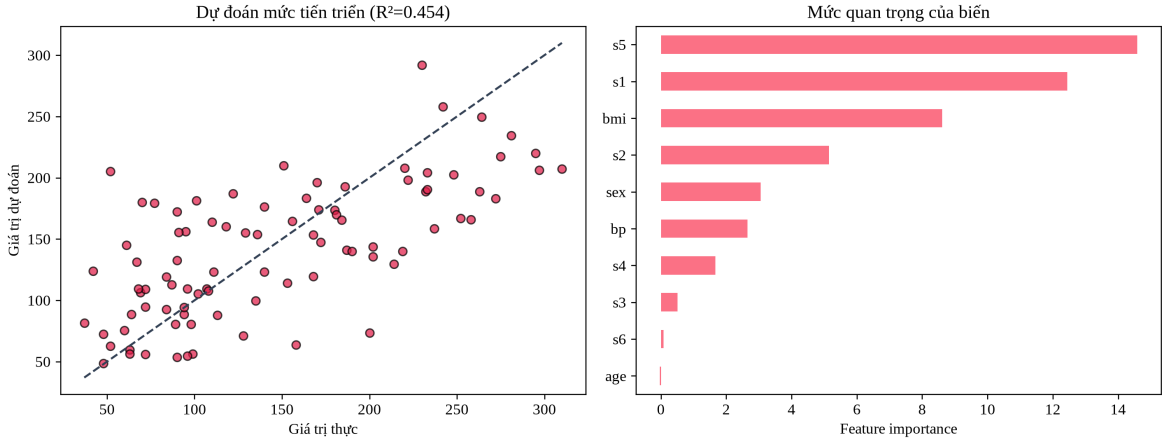
Hình: 4.4.1. ONTOLOGY VÀ XỬ LÝ DỮ LIỆU Y TẾ

4.4.2. THỰC NGHIỆM HỎI ĐÁP Y TẾ

Câu hỏi mẫu hỏi các yếu tố liên quan đến quản lý bệnh tiểu đường. Vector retriever tìm mô tả theo dõi đường huyết, HbA1c, huyết áp, cân nặng, ăn uống và vận động. Đồ thị bổ sung các cạnh nối bệnh với theo dõi và chuyên gia.

Câu trả lời sinh ra trong lần chạy: Theo dõi đường huyết, HbA1c, huyết áp, cân nặng, chế độ ăn và vận động là các thành phần thường gặp trong quản lý bệnh đái tháo đường; quyết định điều trị cần bác sĩ. Bộ dữ liệu diabetes của scikit-learn có 442 quan sát, 10 biến nền đã chuẩn hóa và biến đích phản ánh mức tiến triển bệnh sau một năm. Quan hệ đồ thị liên quan: Bệnh đái tháo đường -[ĐƯỢC_THEO_DÕI_BẰNG]→ Theo dõi HbA1c; Bệnh đái tháo đường -[CẦN_TƯ_VẤN_BỞI]→ Bác sĩ chuyên khoa; Glucose -[LIÊN_QUAN_ĐẾN]→ Bệnh đái tháo đường. Kết quả chỉ có giá trị minh họa; cần tham khảo nhân viên y tế cho quyết định cá nhân.

Biểu đồ đối chiếu giá trị thực - dự đoán và feature importance cho thấy mức độ phù hợp cũng như biến nào được mô hình sử dụng nhiều nhất.



Hình: 4.4.2. THỰC NGHIỆM HỎI ĐÁP Y TẾ

4.4.3. GIỚI HẠN VÀ HƯỚNG MỞ RỘNG Y TẾ

Bộ dữ liệu nhỏ, không đại diện cho dân số Việt Nam và không chứa bối cảnh điều trị. Chỉ số đích mang ý nghĩa nghiên cứu, khác với chẩn đoán đái tháo đường trong thực hành. Vì vậy không thể suy rộng độ chính xác mô hình thành hiệu quả lâm sàng.

Hướng mở rộng là dùng dữ liệu đã khử định danh, xác định rõ biến kết cục, đánh giá theo nhóm tuổi/giới và mời chuyên gia lâm sàng kiểm tra ontology. Ngoài độ chính xác, cần đo calibration, fairness và khả năng giải thích.

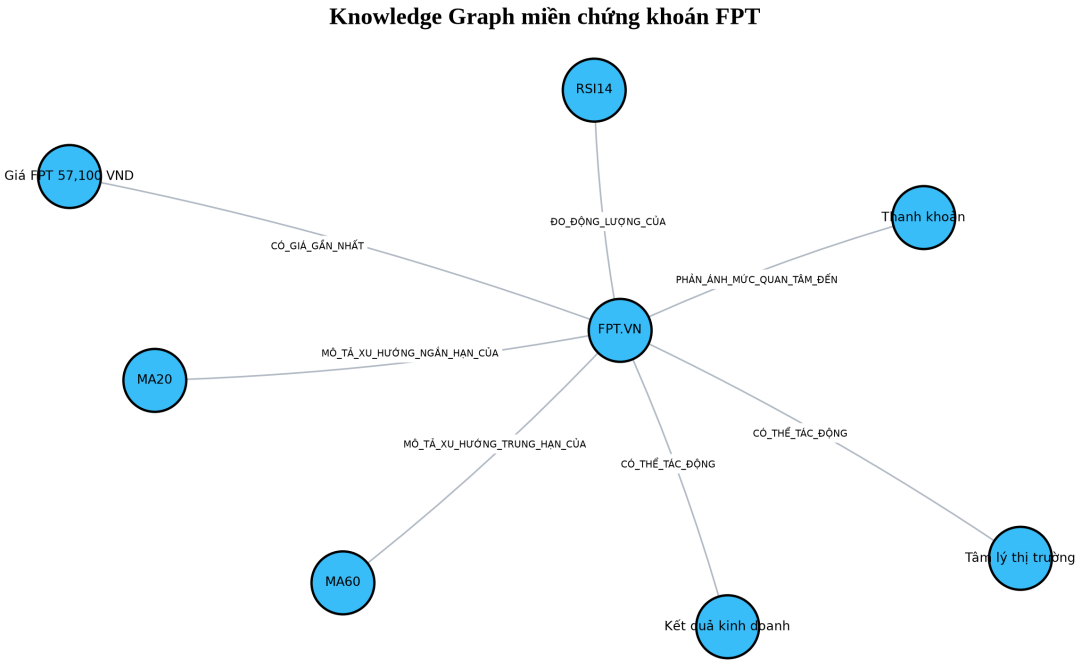
Với RAG y tế, mọi đoạn văn cần version và ngày hiệu lực. Hướng dẫn cũ phải được thu hồi khỏi chỉ mục thay vì chỉ thêm tài liệu mới.

4.5. KB VÀ RAG CHO CHỨNG KHOÁN

Dữ liệu FPT.VN được lấy từ Yahoo Finance chart API - FPT.VN. Khoảng thời gian 15/10/2024 - 15/10/2026 có 523 quan sát. Giá đóng cửa gần nhất là 57,100 VND.

Lợi suất toàn kỳ là -47.28%, biến động năm hóa 30.09%, RSI14 8.7. Mỗi con số được gắn ngày chạy và nguồn dữ liệu.

Knowledge Graph nối FPT.VN với giá gần nhất, MA20, MA60, RSI, thanh khoản, kết quả kinh doanh và tâm lý thị trường. Các quan hệ mô tả vai trò chỉ báo, không tự động tạo khuyến nghị mua bán.



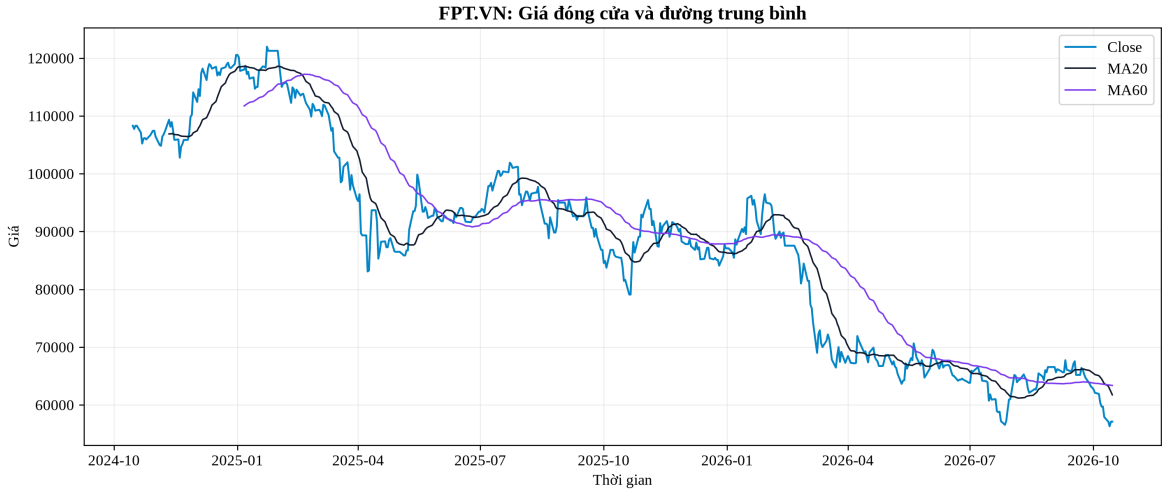
Hình: 4.5. KB VÀ RAG CHO CHỨNG KHOÁN

4.5.1. DỮ LIỆU VÀ TIỀN XỬ LÝ FPT

Chuỗi OHLCV được sắp xếp tăng dần theo ngày; dòng thiếu Close bị loại. Return_1D, MA20, MA60, volatility20 và RSI14 được tính từ dữ liệu lịch sử. Đặc trưng bổ sung gồm thay đổi khối lượng, biên độ High-Low, chênh lệch Open-Close và các độ trễ một phiên.

Tại điểm cuối, MA20 = 61,738, MA60 = 63,367. Bộ học có 340 mẫu train và 85 mẫu test theo thứ tự thời gian.

Biến đích là giá Close của phiên kế tiếp. Việc dịch target một bước rồi drop dòng cuối giúp đặc trưng tại ngày t không chứa giá của ngày t+1.



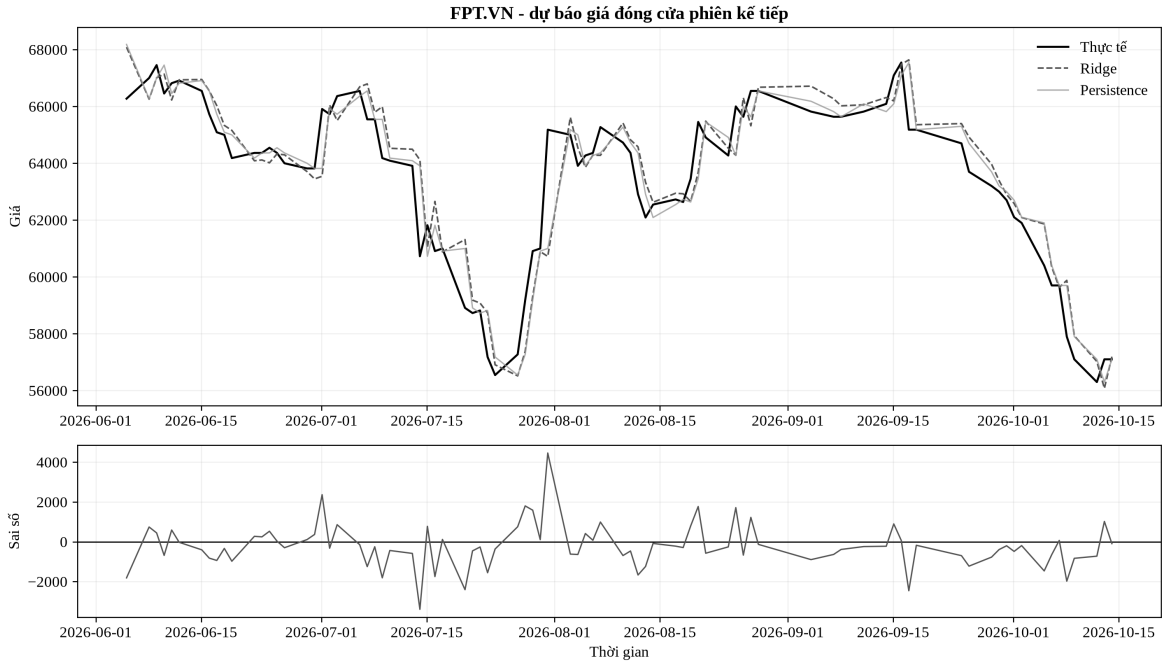
Hình: 4.5.1. DỮ LIỆU VÀ TIỀN XỬ LÝ FPT

4.5.2. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH FPT

Ridge, Random Forest và Gradient Boosting được tuning bằng TimeSeriesSplit 5 phần. Khác K-fold ngẫu nhiên, mỗi fold chỉ huấn luyện trên quá khứ và xác nhận trên đoạn thời gian xảy ra sau đó. Tập test 20% cuối chuỗi không tham gia tuning.

Mô hình được chọn: Ridge; CV MAE = 1898.42; test MAE = 808.59; RMSE = 1119.47; MAPE = 1.28%; R^2 = 0.856.

Độ đúng chiều biến động là 37.6%. Persistence baseline có MAE 716.36; mức cải thiện của mô hình là -12.87%. Báo cáo giữ nguyên kết quả kể cả khi baseline tốt hơn.



Hình: 4.5.2. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH FPT

4.5.3. HỎI ĐÁP CHỨNG KHOÁN VỚI GRAPHRAG

Câu trả lời mẫu: FPT.VN có MA20 61,738, MA60 63,367, RSI14 8.7 và biến động năm hóa 30.1%. Đường trung bình động mô tả xu hướng quá khứ chứ không bảo đảm giá tương lai. RSI là chỉ báo động lượng và cần kết hợp thanh khoản, cơ bản doanh nghiệp cùng bối cảnh thị trường. Quan hệ đồ thị liên quan: FPT.VN -[CÓ_GIÁ_GẦN_NHẤT]→ Giá FPT 57,100 VND; MA20 -[MÔ_TẢ_XU_HƯỚNG_NGẮN_HẠN_CỦA]→ FPT.VN; MA60 -[MÔ_TẢ_XU_HƯỚNG_TRUNG_HẠN_CỦA]→ FPT.VN. Đây là phân tích dữ liệu quá khứ, không phải khuyến nghị mua hoặc bán.

Tài liệu cung cấp số liệu động; đồ thị giải thích vai trò của chỉ báo và liên kết multi-hop. Bộ lọc domain ngăn tài liệu vàng hoặc y tế đi vào câu trả lời chứng khoán.

Kết quả mô hình được ghi thành tài liệu trong KB với model name, thời gian, MAE và R^2. Vì vậy RAG có thể dẫn lại đúng lần huấn luyện thay vì tạo ra độ chính xác không tồn tại.

TimeSeriesSplit cho FPT và giá vàng Tieuluan02_06_Nhom2_Giangkt.ipynb

```
supervised["Target_Next_Close"] = supervised["Close"].shift(-1)
split = int(len(supervised) * 0.8)
train, test = supervised.iloc[:split], supervised.iloc[split:]
tscv = TimeSeriesSplit(n_splits=5)
search = GridSearchCV(
    estimator, param_grid=grid,
    scoring="neg_mean_absolute_error",
    cv=tscv, n_jobs=1, refit=True,
)
search.fit(train[feature_cols], train["Target_Next_Close"])
prediction = search.best_estimator_.predict(test[feature_cols])
persistence = test["Close"].to_numpy()
```

Hình: 4.5.3. HỎI ĐÁP CHỨNG KHOÁN VỚI GRAPHRAG

4.5.4. RỦI RO VÀ HƯỚNG MỞ RỘNG

Corporate actions, thanh khoản, cách điều chỉnh giá và survivorship bias có thể làm sai phân tích. Yahoo Finance phù hợp bài tập nhưng nên đối chiếu nguồn chính thức nếu dùng trong nghiên cứu giao dịch.

Dự báo Close phiên kế tiếp thường có R^2 cao do giá hôm nay gần giá ngày mai; vì vậy phải đọc cùng persistence baseline và directional accuracy. R^2 cao không đồng nghĩa chiến lược có lợi nhuận.

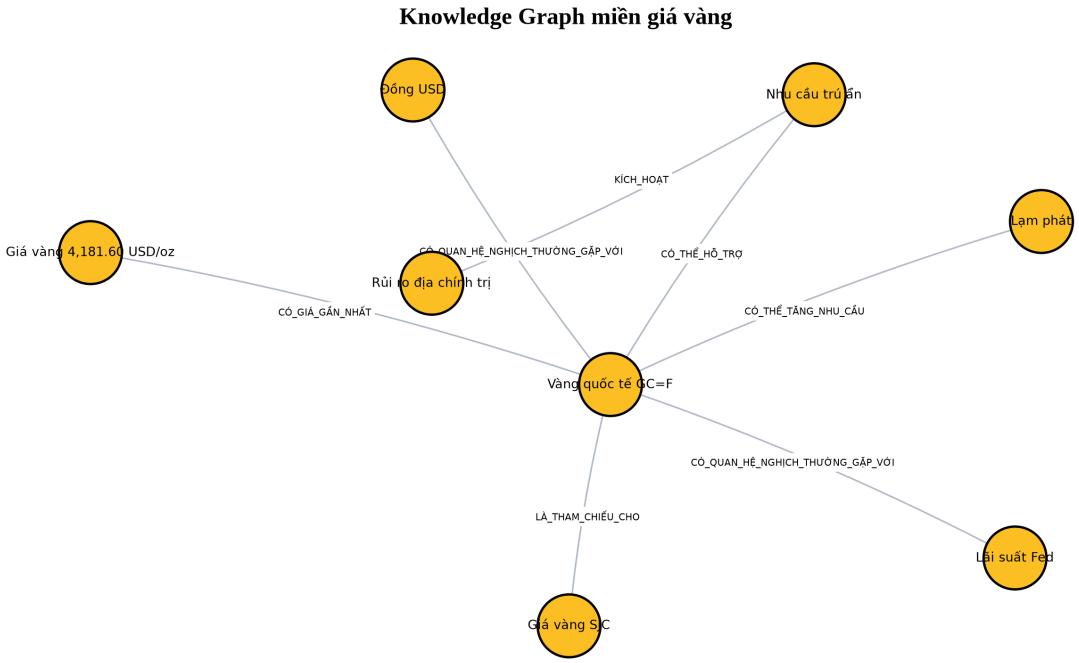
Hướng mở rộng là walk-forward backtest có phí, trượt giá, khoảng tin cậy và kiểm tra thay đổi chế độ thị trường. Mọi đầu ra vẫn cần cảnh báo không phải khuyến nghị đầu tư.

4.6. KB VÀ RAG CHO GIÁ VÀNG

Dữ liệu hợp đồng vàng GC=F được lấy từ Yahoo Finance chart API - GC=F. Khoảng 15/10/2024 - 15/10/2026 có 504 quan sát; giá gần nhất 4,181.60 USD/oz.

Lợi suất toàn kỳ 56.09%, biến động năm hóa 24.40%, RSI14 37.7. GC=F là tham chiếu quốc tế, không đồng nhất với giá vàng miếng SJC.

Knowledge Graph mô tả lãi suất Fed, USD, lạm phát, địa chính trị và nhu cầu trú ẩn. Những cạnh này là khung giải thích có điều kiện, không phải quan hệ nhân quả cố định.



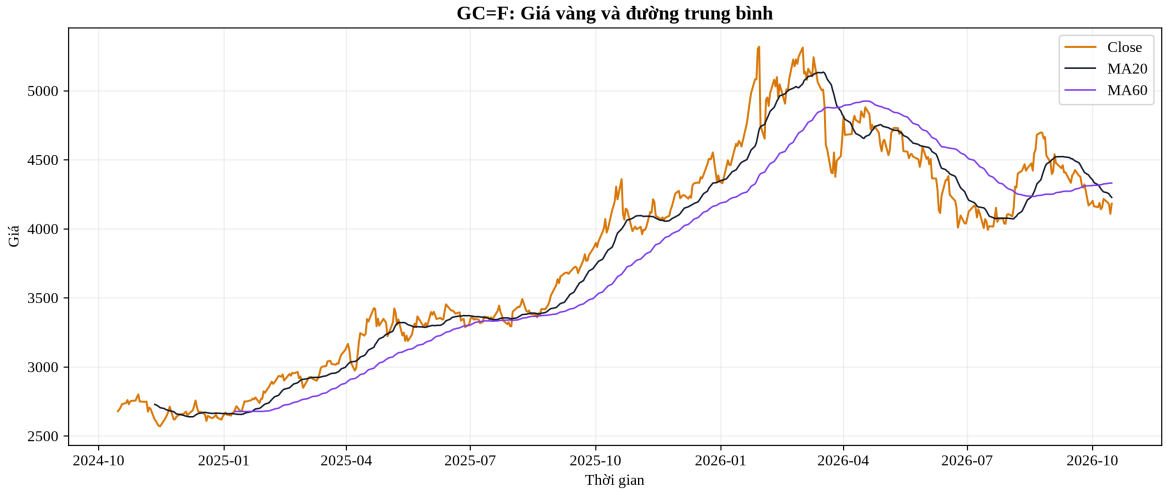
Hình: 4.6. KB VÀ RAG CHO GIÁ VÀNG

4.6.1. DỮ LIỆU, CHỈ BÁO VÀ KNOWLEDGE GRAPH VÀNG

MA20 hiện là 4,226.87, MA60 là 4,331.32. Chuỗi giữ nguyên lịch phiên của nguồn; không nội suy ngày nghỉ. Biến đích là Close phiên kế tiếp.

Đặc trưng dùng cùng một công thức với FPT để so sánh công bằng: giá và độ trễ, return, MA20, MA60, volatility20, RSI14, thay đổi volume, biên độ ngày và chênh lệch Open-Close.

Chuỗi Rủi ro địa chính trị -> Nhu cầu trú ẩn -> Vàng quốc tế minh họa truy vấn nhiều bước. Quan hệ Vàng quốc tế -> Giá vàng SJC chỉ là tham chiếu, cần thêm tỷ giá và cơ chế thị trường trong nước để giải thích chênh lệch.



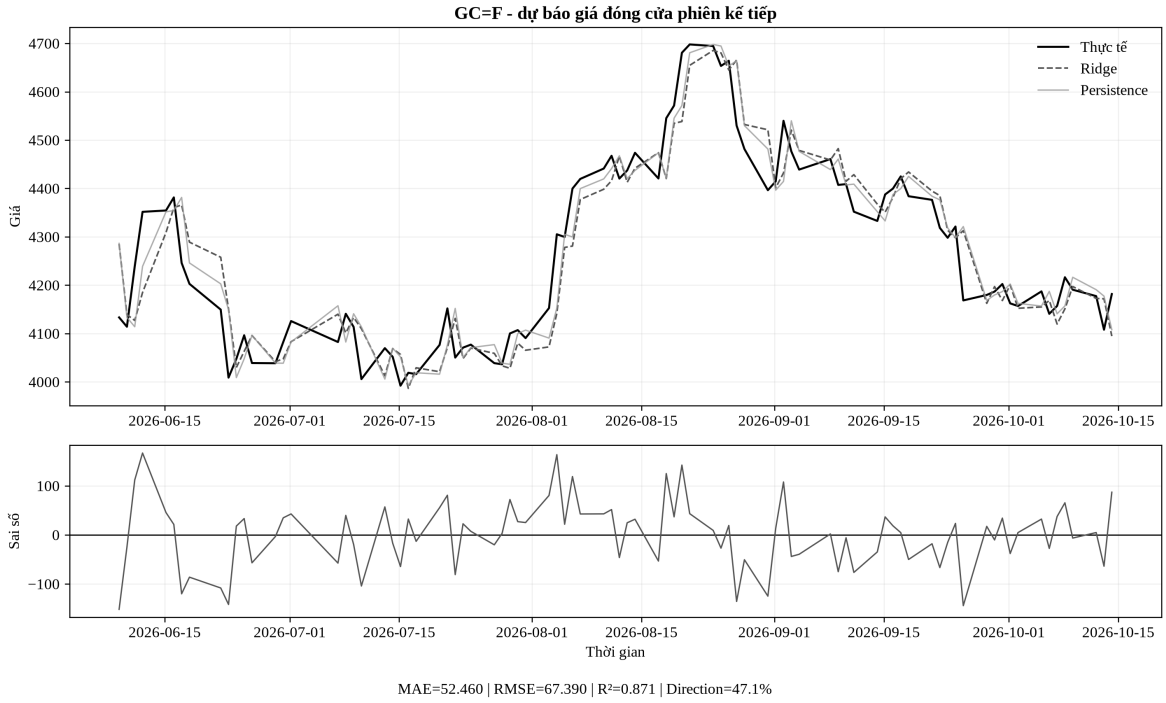
Hình: 4.6.1. DỮ LIỆU, CHỈ BÁO VÀ KNOWLEDGE GRAPH VÀNG

4.6.2. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH VÀNG

Ridge, Random Forest và Gradient Boosting được tuning bằng TimeSeriesSplit 5 phần trên 80% đầu chuỗi. 20% cuối được dùng duy nhất cho kiểm thử ngoài mẫu. Tiêu chí lựa chọn là CV MAE.

Mô hình được chọn: Ridge; CV MAE = 61.837; test MAE = 52.460; RMSE = 67.390; MAPE = 1.23%; R^2 = 0.871.

Độ đúng chiều là 47.1%. Persistence baseline có MAE 48.560; mức cải thiện là -8.03%. Các chỉ số được tính trực tiếp từ phần test theo thời gian.



Hình: 4.6.2. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH VÀNG

4.6.3. HỎI ĐÁP VĨ MÔ VỚI GRAPHRAG

Câu trả lời mẫu: Giá vàng thường nhạy với lãi suất thực, sức mạnh đồng USD, kỳ vọng lạm phát, nhu cầu dự trữ và rủi ro địa chính trị; quan hệ có thể thay đổi theo từng giai đoạn. Chuỗi vàng GC=F gồm 504 phiên từ 15/10/2024 đến 15/10/2026; giá gần nhất 4,181.60 USD/oz. Quan hệ đồ thị liên quan: Vàng quốc tế GC=F -[CÓ_GIÁ_GẦN_NHẤT]→ Giá vàng 4,181.60 USD/oz; Vàng quốc tế GC=F -[LÀ_THAM_CHIẾU_CHO]→ Giá vàng SJC; Lãi suất Fed -[CÓ_QUAN_HỆ_NGHỊCH_THƯỜNG_GẶP_VỚI]→ Vàng quốc tế GC=F. Đây là phân tích dữ liệu quá khứ, không phải khuyến nghị mua hoặc bán.

Truy xuất văn bản nêu điều kiện và độ bất định; đồ thị cung cấp các cạnh thường gặp và đường đi qua nhu cầu trú ẩn. Hai nguồn bằng chứng cùng xuất hiện giúp câu trả lời tránh tuyệt đối hóa.

Nếu thay bộ sinh mẫu bằng LLM, prompt phải cấm tự tạo mục tiêu giá hoặc xác suất tăng giảm khi evidence không cung cấp. Citation ID và timestamp nên là trường bắt buộc trong JSON đầu ra.

GraphRAG: ghép bằng chứng văn bản và bộ ba Tieuluan02_06_Nhom2_Giangkt.ipynb

```
def graphrag_answer(query, top_k=3):
    docs = retriever.search(query, top_k=top_k)
    triples = graph_evidence(query)
    domain = detect_domain(query)
    domain_docs = [d for d in docs if d["domain"] in (domain, "method")]
    statements = [d["text"] for d in domain_docs[:2]]
    graph_text = [f"{s} -[{p}]-> {o}" for s, p, o in triples[:3]]
    answer = " ".join(statements)
    if graph_text:
        answer += " Quan hệ đồ thị: " + "; ".join(graph_text)
    return {"answer": answer, "documents": domain_docs, "triples": triples}
```

Hình: 4.6.3. HỎI ĐÁP VĨ MÔ VỚI GRAPHRAG

4.6.4. GIỚI HẠN VÀ HƯỚNG MỞ RỘNG

Hợp đồng tương lai có ngày đáo hạn và cơ chế nối chuỗi. Spot XAU/USD, futures GC=F và vàng SJC là ba sản phẩm khác nhau; không thể trộn USD/oz với VND/lượng nếu chưa quy đổi.

Mô hình hiện chưa dùng lãi suất thực, DXY, tỷ giá USD/VND hay vị thế ETF. Hướng mở rộng là gắn timestamp cho các yếu tố vĩ mô, thử độ trễ và lưu confidence cùng evidence trên mỗi cạnh.

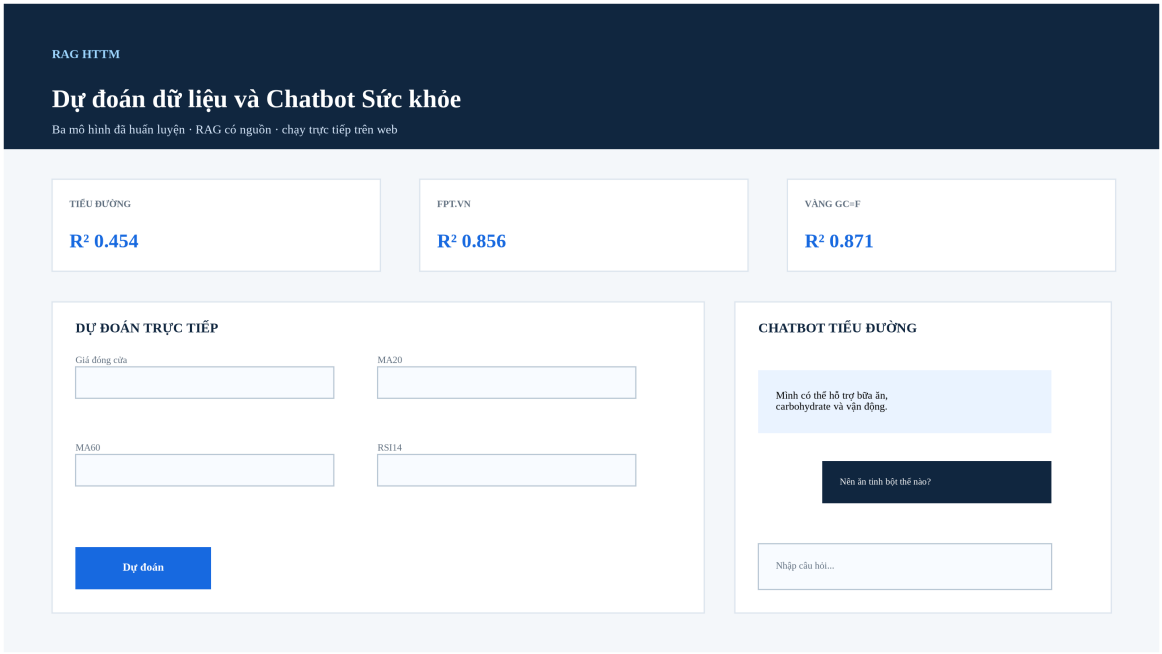
Tương tự chứng khoán, dự báo một bước chỉ minh họa quy trình machine learning có kiểm soát. Nó không phải khuyến nghị mua, bán hay nắm giữ vàng.

4.7. DEPLOYMENT

Notebook sinh một ứng dụng web tương tác trong vercel_app. Người dùng có thể nhập biến tiểu đường, chỉ báo FPT hoặc chỉ báo vàng rồi nhận dự đoán ngay trên trình duyệt. Kết quả không phải số viết sẵn: notebook xuất mean, scale, coefficient và intercept từ đúng pipeline đã huấn luyện sang JavaScript.

Cùng trang web có Chatbot Sức khỏe & Dinh dưỡng Bệnh Tiểu đường. Bộ truy xuất chấm điểm từ khóa, chọn đoạn phù hợp trong kho tri thức và đưa cả nguồn lẫn quan hệ Knowledge Graph vào câu trả lời. Nội dung dựa trên WHO, CDC và ADA; chatbot không chẩn đoán hoặc thay đổi liều thuốc.

Ứng dụng đã triển khai tại https://rag-httm-ai.vercel.app. Mã nguồn và notebook đặt tại https://github.com/jellalaz/RAG_HTTM.



Hình: 4.7. DEPLOYMENT

4.7.1. SUY LUẬN MÔ HÌNH TRÊN TRÌNH DUYỆT

Phần compute nặng gồm tải dữ liệu, tạo đặc trưng, cross-validation và fit mô hình chạy trong notebook. Phần web chỉ nhận tham số cuối cùng của StandardScaler và Ridge. Với từng mẫu x, trình duyệt tính z=(x-mean)/scale, sau đó y=intercept+sum(coef*z). Vì vậy cùng đầu vào sẽ cho cùng kết quả như pipeline Python.

Biểu mẫu tiểu đường dùng đủ 10 thuộc tính của bộ dữ liệu scikit-learn. Hai biểu mẫu thị trường hiển thị sáu biến dễ diễn giải; năm biến còn lại lấy từ quan sát mới nhất nhưng vẫn tham gia phép dự đoán. Ngày dữ liệu và đơn vị được hiển thị ngay cạnh biểu mẫu.

Kiến trúc tĩnh phù hợp Vercel: không cần lưu API key, phản hồi tức thời và không gửi dữ liệu biểu mẫu về máy chủ. Khi cập nhật dữ liệu, chỉ cần Run All notebook và deploy lại index.html.

Xuất mô hình và chatbot RAG lên Vercel Tieuluan02_06_Nhom2_Giangkt.ipynb

```
model_config = export_linear_pipeline(model, feature_names)
model_json = json.dumps(model_config, ensure_ascii=False)
kb_json = json.dumps(health_kb, ensure_ascii=False)
html = (html_template
        .replace("__MODEL_CONFIG__", model_json)
        .replace("__HEALTH_KB__", kb_json))
(WEB_DIR / "index.html").write_text(html, encoding="utf-8")
# Triển khai: cd vercel_app && npx vercel --prod
```

Hình: 4.7.1. SUY LUẬN MÔ HÌNH TRÊN TRÌNH DUYỆT

4.7.2. CHATBOT RAG SỨC KHỎE VÀ DINH DƯỠNG

Kho tri thức chatbot bao gồm phương pháp chiếc đĩa, carbohydrate, vận động, theo dõi đường huyết và xử trí tình huống khẩn cấp. Câu hỏi tiếng Việt được chuẩn hóa dấu, so khớp với cụm từ khóa có trọng số, rồi lấy tài liệu đạt điểm cao nhất.

Mỗi phản hồi hiển thị tên nguồn và một đường bằng chứng dạng subject - relation - object. Cách trình bày này giúp người đọc phân biệt nội dung tài liệu với cấu trúc KG. Nếu câu hỏi chứa dấu hiệu như bất tỉnh, co giật hoặc khó thở, hệ thống ưu tiên hướng dẫn tìm trợ giúp khẩn cấp.

Chatbot là công cụ giáo dục sức khỏe. Nó không thu thập bệnh án, không chẩn đoán, không kê đơn và không thay thế bác sĩ. Những câu hỏi cá nhân về mục tiêu đường huyết hoặc liều thuốc được hướng về nhân viên y tế.

4.7.3. KIỂM THỬ TRIỂN KHAI

Kiểm thử gồm ba lớp: so sánh phép tính JavaScript với pipeline Python, smoke test ba nút dự đoán, và thử các nhóm câu hỏi ăn uống, vận động, theo dõi cùng tình huống khẩn cấp. Liên kết nguồn phải mở đúng trang WHO, CDC hoặc ADA.

Trước khi nộp, PDF được render thành ảnh để kiểm tra font, mục lục, số trang và độ nét. Web được kiểm tra trên bố cục desktop và responsive, đặc biệt là khả năng nhập số, chuyển tab và gửi câu hỏi bằng phím Enter.

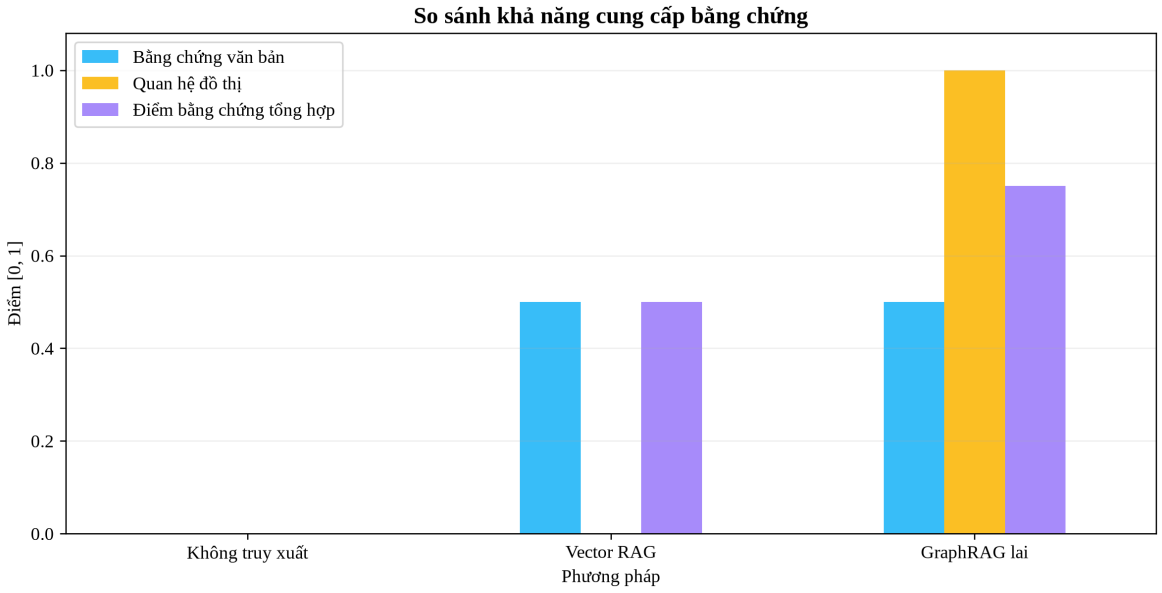
Deployment hoàn thành khi URL production truy cập được, ba biểu mẫu trả kết quả, chatbot trả bằng chứng và số liệu mô hình khớp với lần chạy notebook tạo báo cáo.

ĐÁNH GIÁ TỔNG HỢP

Kết quả cho thấy một notebook có thể bao quát tải dữ liệu, tiền xử lý, KG, RAG, đánh giá, báo cáo và web. GraphRAG lai cung cấp thêm loại bằng chứng mà Vector RAG không có: quan hệ có tên và đường đi giữa các thực thể.

Đổi lại, KG yêu cầu thiết kế ontology, kiểm soát quan hệ và cập nhật theo thời gian. Chi phí này chỉ đáng bỏ ra khi bài toán cần giải thích, liên kết đa bước hoặc quản trị tri thức dài hạn.

Bài làm đạt mục tiêu nguyên mẫu tái lập. Hạn chế chính là corpus nhỏ, đánh giá ít câu hỏi, generator dạng mẫu và chưa có chuyên gia miền thẩm định. Những giới hạn này được ghi rõ thay vì suy rộng kết quả.



Hình: ĐÁNH GIÁ TỔNG HỢP

KẾT LUẬN

Knowledge Graph và RAG bổ trợ nhau theo cách thực dụng: văn bản đem lại ngữ cảnh linh hoạt, đồ thị đem lại cấu trúc và provenance. Trên ba miền thử nghiệm, cùng một pipeline vẫn giữ được nguồn, thời điểm và cảnh báo riêng.

Điều quan trọng nhất rút ra là không nên coi GraphRAG như một nhãn công nghệ thay thế cho thiết kế dữ liệu. Chất lượng câu trả lời bắt đầu từ việc định nghĩa thực thể, quan hệ, nguồn và phạm vi kết luận.

Notebook kèm theo là sản phẩm có thể chạy lại. PDF và dashboard chỉ là hai cách trình bày cùng một trạng thái kết quả, nhờ đó giảm sai lệch giữa code và báo cáo.

PHỤ LỤC A - TỔNG HỢP HUẤN LUYỆN BA MIỀN

Miền	Mô hình được chọn	CV MAE	Test MAE	Test R^2
Tiểu đường	Ridge	44.999	42.812	0.454
Chứng khoán FPT	Ridge	1898.417	808.593	0.856
Giá vàng GC=F	Ridge	61.837	52.460	0.871

Mô hình được chọn theo CV MAE trên tập train. Chỉ số test được tính đúng một lần trên phần dữ liệu giữ lại.

PHỤ LỤC B - KẾT QUẢ TRUY XUẤT

Câu hỏi	Miền	P@3	Graph	Hybrid
Theo dõi gì khi quản lý bệnh tiểu đường?	diabetes	0.67	1	0.92
Mô hình tiểu đường có sai số bao nhiêu?	diabetes	0.33	1	0.58
Giá FPT gần nhất và RSI là bao nhiêu?	stock	0.67	1	0.92
MA20 của cổ phiếu có ý nghĩa gì?	stock	0.33	1	0.58
Giá vàng gần nhất là bao nhiêu?	gold	0.33	1	0.58
Fed, USD và địa chính trị ảnh hưởng vàng ra sao?	gold	0.67	1	0.92

Bảng này là phép kiểm tra hồi quy cho pipeline. Nó không thay thế đánh giá câu trả lời bởi chuyên gia.

PHỤ LỤC C - MẪU BỘ BA TRI THỨC

Subject	Predicate	Object
Bệnh đái tháo đường	ĐƯỢC_THEO_DÕI_BẰNG	Theo dõi HbA1c
Bệnh đái tháo đường	CẦN_TƯ_VẤN_BỞI	Bác sĩ chuyên khoa
Glucose	LIÊN_QUAN_ĐẾN	Bệnh đái tháo đường
BMI	LÀ_YẾU_TỐ_NGUY_CƠ_CỦA	Bệnh đái tháo đường
Huyết áp	CẦN_THEO_DÕI_KHI	Bệnh đái tháo đường
Tuổi	ĐIỀU_CHỈNH_NGUY_CƠ	Bệnh đái tháo đường
Chế độ ăn	HỖ_TRỢ_QUẢN_LÝ	Bệnh đái tháo đường
Vận động	HỖ_TRỢ_QUẢN_LÝ	Bệnh đái tháo đường
FPT.VN	CÓ_GIÁ_GẦN_NHẤT	Giá FPT 57,100 VND
MA20	MÔ_TẢ_XU_HƯỚNG_NGẮN_HẠN_CỦA	FPT.VN
MA60	MÔ_TẢ_XU_HƯỚNG_TRUNG_HẠN_CỦA	FPT.VN
RSI14	ĐO_ĐỘNG_LƯỢNG_CỦA	FPT.VN
Thanh khoản	PHẢN_ÁNH_MỨC_QUAN_TÂM_ĐẾN	FPT.VN
Kết quả kinh doanh	CÓ_THỂ_TÁC_ĐỘNG	FPT.VN
Tâm lý thị trường	CÓ_THỂ_TÁC_ĐỘNG	FPT.VN
Vàng quốc tế GC=F	CÓ_GIÁ_GẦN_NHẤT	Giá vàng 4,181.60 USD/oz
Vàng quốc tế GC=F	LÀ_THAM_CHIẾU_CHO	Giá vàng SJC
Lãi suất Fed	CÓ_QUAN_HỆ_NGHỊCH_THƯỜNG_GẶP_VỚI	Vàng quốc tế GC=F
Đồng USD	CÓ_QUAN_HỆ_NGHỊCH_THƯỜNG_GẶP_VỚI	Vàng quốc tế GC=F
Lạm phát	CÓ_THỂ_TĂNG_NHU_CẦU	Vàng quốc tế GC=F

TÀI LIỆU THAM KHẢO

[1] W3C, RDF 1.1 Concepts and Abstract Syntax, W3C Recommendation, 2014.

[2] T. Berners-Lee, J. Hendler, O. Lassila, The Semantic Web, Scientific American, 2001.

[3] K. Guu et al., REALM: Retrieval-Augmented Language Model Pre-Training, ICML, 2020.

[4] P. Lewis et al., Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, NeurIPS, 2020.

[5] D. Edge et al., From Local to Global: A Graph RAG Approach to Query-Focused Summarization, 2024.

[6] scikit-learn developers, Diabetes dataset and TfidfVectorizer documentation.

[7] NetworkX developers, MultiDiGraph documentation.

[8] Yahoo Finance chart endpoint, mã FPT.VN và GC=F; truy cập tại thời điểm chạy notebook.

[9] World Health Organization, Diabetes fact sheet, https://www.who.int/news-room/fact-sheets/detail/diabetes.

[10] Centers for Disease Control and Prevention, Diabetes Meal Planning, https://www.cdc.gov/diabetes/healthy-eating/diabetes-meal-planning.html.

[11] American Diabetes Association, Eating Healthy, https://diabetes.org/food-nutrition/eating-healthy.

[12] Vercel Documentation, Static Deployments and CLI.

[13] Mã nguồn bài làm: https://github.com/jellalaz/RAG_HTTM.

[14] Web triển khai: https://rag-httm-ai.vercel.app.

Báo cáo được sinh tự động từ notebook lúc 16/10/2026 02:36:39 +07. Dữ liệu nguồn: FPT - Yahoo Finance chart API - FPT.VN; vàng - Yahoo Finance chart API - GC=F.